



Big Data y Análisis de Datos

MATERIAL TÉCNICO DE APOYO

TAREA N° 01

Define los fundamentos e importancia del Big Data.

1. FUNDAMENTOS DEL BIG DATA: DEFINICIÓN, CARACTERÍSTICAS Y EVOLUCIÓN DEL CONCEPTO.

- **Definición**


Big Data se refiere al conjunto de datos masivos y complejos que no pueden ser gestionados con herramientas tradicionales debido a su volumen, velocidad y variedad.



[Big Data](#)

- **Características**

- **Volumen:** Cantidades enormes de datos (ej. redes sociales, sensores, transacciones).
- **Velocidad:** Rapidez con la que se generan y procesan (ej. Twitter genera 500 millones de tuits/día).
- **Variedad:** Diversos formatos de datos (texto, imagen, video, logs, etc.).
- **Veracidad:** Fiabilidad de los datos (datos ruidosos o inconsistentes).
- **Valor:** Utilidad que se puede obtener a partir del análisis de esos datos.



5V

- **Evolución del concepto**

- **Antes:** Las bases de datos relacionales eran suficientes.
- **Ahora:** Con la digitalización masiva, necesitamos nuevas tecnologías como Hadoop, Spark y NoSQL.
- **Tendencia:** Integración con Inteligencia Artificial y análisis en tiempo real.

2. ARQUITECTURA GENERAL DE SOLUCIONES BIG DATA: CAPAS DE ADQUISICIÓN, ALMACENAMIENTO, PROCESAMIENTO Y VISUALIZACIÓN.

- **Capa de Adquisición (Ingesta):**
 - **Función:** Recoge datos desde múltiples fuentes (IoT, apps, redes sociales).
 - **Ejemplo:** Apache Kafka, Flume, NiFi.
- **Capa de Almacenamiento:**
 - **Función:** Guarda grandes volúmenes de datos de forma escalable.
 - **Ejemplo:** HDFS, Amazon S3, Cassandra.


- **Capa de Procesamiento:**

- **Función:** Transforma y analiza los datos.
- **Procesamiento por lotes:** Apache Hadoop.
- **Procesamiento en tiempo real:** Apache Spark, Storm.

- **Capa de Visualización:**

- **Función:** Muestra resultados comprensibles para la toma de decisiones.
- **Ejemplo:** Tableau, Power BI, Grafana.

3. TIPOS DE DATOS: ESTRUCTURADOS, SEMI-ESTRUCTURADOS Y NO ESTRUCTURADOS.



[Tipos de datos](#)

- **Estructurados:**

- **Definición:** Datos organizados en tablas, filas y columnas.
- **Ejemplo:** Bases de datos SQL (MySQL, Oracle).
- **Ventaja:** Fáciles de consultar y procesar.

- **Semi-estructurados:**

- **Definición:** Datos con estructura flexible, sin cumplir una forma rígida de tabla.

- **Ejemplo:** JSON, XML, logs.
- **Ventaja:** Adaptables a múltiples formatos.
- **No Estructurados:**
 - **Definición:** Datos sin estructura predefinida.
 - **Ejemplo:** Imágenes, videos, audios, correos electrónicos.
 - **Ventaja:** Ricos en información, pero requieren técnicas avanzadas para analizarlos (IA, NLP).

4. FUENTES DE GENERACIÓN DE DATOS MASIVOS: REDES SOCIALES, SENSORES IOT, TRANSACCIONES, LOGS.

Las fuentes de Big Data son diversas y crecen rápidamente con la digitalización. Aquí van las principales:

- **Redes Sociales:**



[Redes sociales](#)

- **Ejemplos:** Facebook, Instagram, Twitter, TikTok.
- **Tipo de datos:** Likes, comentarios, publicaciones, hashtags, ubicación.
- **Uso:** Análisis de sentimiento, tendencias, comportamiento del consumidor.
- **Sensores IoT (Internet of Things):**
 - **Ejemplos:** Smartwatches, termostatos, autos conectados, sensores industriales.
 - **Tipo de datos:** Temperatura, ubicación, presión, movimiento.

- **Uso:** Mantenimiento predictivo, monitoreo en tiempo real, ciudades inteligentes.
- **Transacciones:**



[Transacciones](#)

- **Ejemplos:** Compras con tarjeta, pagos móviles, banca online.
- **Tipo de datos:** Monto, hora, ubicación, ID cliente.
- **Uso:** Detección de fraudes, análisis de consumo, personalización de ofertas.
- **Logs del sistema:**
 - **Ejemplos:** Registros de actividad en servidores, aplicaciones o redes.
 - **Tipo de datos:** Errores, accesos, caídas.
 - **Uso:** Seguridad informática, auditorías, monitoreo de rendimiento.

5. SISTEMAS DE INFORMACIÓN Y SU INTEGRACIÓN CON BIG DATA: ERP, CRM, SCM.



[CRM, ERP y SCM](#)

- **ERP (Enterprise Resource Planning):**
 - **Ejemplo:** SAP, Oracle ERP.
 - **Función:** Gestiona procesos internos: finanzas, producción, recursos humanos.
 - **Con Big Data:** Permite análisis predictivo de inventarios, costos y desempeño del personal.
- **2. CRM (Customer Relationship Management):**
 - **Ejemplo:** Salesforce, Zoho CRM.
 - **Función:** Administra la relación con clientes.
 - **Con Big Data:** Analiza patrones de compra, preferencias, satisfacción y comportamiento.
- **3. SCM (Supply Chain Management):**
 - **Ejemplo:** SAP SCM, Oracle SCM Cloud.
 - **Función:** Coordina logística, inventario, transporte y proveedores.
 - **Con Big Data:** Optimiza rutas, predice demoras, analiza la eficiencia del proveedor.

6. INTRODUCCIÓN AL CLOUD COMPUTING: DEFINICIÓN, TIPOS DE SERVICIOS (IAAS, PAAS, SAAS) Y SU RELACIÓN CON EL PROCESAMIENTO DE BIG DATA.

Es el acceso bajo demanda a recursos de computación (servidores, bases de datos, almacenamiento, software) a través de internet, sin necesidad de comprarlos o mantenerlos físicamente.



[Tipos de servicios](#)

- **Tipos de servicios:**

- **IaaS (Infrastructure as a Service):**

- **Ejemplo:** Amazon EC2, Microsoft Azure VM.
 - **Uso:** Alquiler de servidores, redes, almacenamiento.
 - **Ventaja:** Control total sobre la infraestructura.

- **PaaS (Platform as a Service):**

- **Ejemplo:** Google App Engine, Azure App Service.
 - **Uso:** Desarrollo de apps sin preocuparse del hardware.
 - **Ventaja:** Desarrolladores pueden enfocarse solo en el código.

- **SaaS (Software as a Service):**

- **Ejemplo:** Google Drive, Microsoft 365, Dropbox.
- **Uso:** Aplicaciones listas para usar.
- **Ventaja:** No requiere instalación ni mantenimiento.

- **Relación con Big Data:**



[Relación con Big Data](#)

- Permite escalar fácilmente almacenamiento y procesamiento.
- Acceso global y en tiempo real.
- Reduce costos de infraestructura.

TAREA N°02**Conoce el almacenamiento de datos masivos.****1. ARQUITECTURA BIG DATA: CAPAS DE INGESTA, ALMACENAMIENTO, PROCESAMIENTO Y VISUALIZACIÓN.**

- **Capa de Ingesta (Adquisición):**
 - **Función:** Captura datos desde diversas fuentes (sensores, apps, redes sociales, logs).
 - **Tecnologías:** Apache Kafka, Apache Flume, AWS Kinesis.
 - **Ejemplo:** Recoger datos en tiempo real desde sensores de una fábrica.
- **Capa de Almacenamiento:**
 - **Función:** Guarda los datos en forma estructurada o no estructurada.
 - **Tecnologías:** HDFS, Amazon S3, Google Cloud Storage.
 - **Ejemplo:** Archivar millones de fotos subidas por usuarios.
- **Capa de Procesamiento:**
 - **Función:** Transforma y analiza los datos.
 - **Por lotes:** Apache Hadoop.
 - **En tiempo real:** Apache Spark, Apache Flink.
 - **Ejemplo:** Analizar patrones de compra en tiempo real.
- **Capa de Visualización:**
 - **Función:** Mostrar resultados para la toma de decisiones.
 - **Herramientas:** Power BI, Tableau, Grafana.
 - **Ejemplo:** Dashboard de ventas globales con filtros interactivos.

2. SISTEMAS DE ARCHIVOS DISTRIBUIDOS: DEFINICIÓN, FUNCIONAMIENTO, VENTAJAS Y DESVENTAJAS DE HDFS (HADOOP DISTRIBUTED FILE SYSTEM) Y GFS (GOOGLE FILE SYSTEM).

Los sistemas de archivos distribuidos permiten almacenar datos a través de múltiples servidores, como si fuera un único disco virtual gigante. Son claves en Big Data por su capacidad de escalar.

- **HDFS (Hadoop Distributed File System):**



[HDFS](#)

- **Funcionamiento:**

- Divide los archivos grandes en bloques (por defecto de 128MB).
- Los bloques se replican en varios nodos (por seguridad).
- **Componentes:** NameNode (gestiona metadatos) y DataNodes (almacenan datos).

- **Ventajas:**

- Escalabilidad horizontal.
- Alta tolerancia a fallos.
- Compatible con Hadoop.

- **Desventajas:**

- No es óptimo para archivos pequeños.
- Alta dependencia del NameNode.

- **GFS (Google File System):**



[GFS](#)

- **Funcionamiento:**

- Similar a HDFS pero desarrollado por Google.
- Diseñado para grandes archivos que se leen muchas veces.

- **Ventajas:**

- Altamente escalable.
- Buen rendimiento para lecturas masivas.

- **Desventajas:**

- Uso cerrado a Google internamente.
- Menor flexibilidad para otros entornos.

3. BASES DE DATOS NOSQL: DEFINICIÓN, CARACTERÍSTICAS (ESCALABILIDAD HORIZONTAL, AUSENCIA DE ESQUEMA FIJO, ETC.), COMPARACIÓN CON BASES DE DATOS RELACIONALES.

Las bases de datos NoSQL (Not Only SQL) fueron creadas para manejar grandes volúmenes de datos no estructurados o semi-estructurados, con alta disponibilidad y escalabilidad.

- **Características clave:**
 - **Escalabilidad horizontal:** Se pueden añadir más servidores fácilmente.
 - **Ausencia de esquema fijo:** No necesitas definir tablas con columnas antes.
 - **Alta disponibilidad:** Preparadas para trabajar incluso si hay fallos.
 - **Tipos principales:**
 - Documentales (MongoDB)
 - Clave-valor (Redis)
 - Columnar (Cassandra)
 - Grafos (Neo4j)
- **Comparación con bases relacionales:**

Característica	Relacional (SQL)	NoSQL
Esquema	Fijo (tablas)	Flexible (dinámico)
Escalabilidad	Vertical (mejor hardware)	Horizontal (más servidores)
Consistencia	Alta (ACID)	Eventual o configurable
Estructura de datos	Tablas y relaciones	Documentos, grafos, pares
Ideal para	Sistemas bancarios, ERP	Big Data, redes sociales

[Comparación \[Elaboración propia\]](#)

4. TIPOS DE BASES DE DATOS NOSQL: DOCUMENTALES (MONGODB), DE COLUMNAS (CASSANDRA), CLAVE-VALOR (REDIS), GRAFOS (NEO4J).

NoSQL se adapta al tipo de dato y necesidad. Aquí sus principales tipos:

- **Documentales (Ej: MongoDB)**
 - Almacenan datos como documentos JSON o BSON.
 - Muy usados en aplicaciones web y móviles.
 - **Ejemplo:** Un documento JSON con los datos de un usuario (nombre, edad, dirección).


```
{
  "nombre": "Ana",
  "edad": 22,
  "intereses": ["música", "lectura"]
}
```

Flexible, ideal para datos semi-estructurados.

Puede ser menos eficiente con relaciones complejas

- **De Columnas (Ej: Cassandra)**

- Organiza datos por columnas en vez de filas.
- Eficiente para consultas a gran escala en una sola columna.
- Muy rápido para lecturas masivas.
- No ideal para transacciones complejas.

- **Clave-Valor (Ej: Redis)**

- Almacena pares clave:valor, como un diccionario.
- Extremadamente rápido y ligero.
- Ideal para cachés y sesiones de usuarios.
- No apto para consultas complejas.

- **Grafos (Ej: Neo4j)**

- Diseñado para manejar relaciones entre datos.
- Ideal para redes sociales, rutas, recomendaciones.
- Eficiente en búsquedas de conexiones.
- Menos popular para estructuras simples.

5. ESTRUCTURAS DE DATOS JSON: USO EN BASES NOSQL, VENTAJAS PARA INTERCAMBIO Y ALMACENAMIENTO.

- **¿Qué es JSON (JavaScript Object Notation)?**

Es un formato de texto ligero, fácil de leer y escribir, usado para almacenar y transportar datos.

- **Uso en bases NoSQL**

MongoDB y otras bases documentales almacenan y consultan datos directamente en formato JSON.

- No requiere esquema fijo.
- Puede anidarse (listas, objetos dentro de objetos).

- **Ventajas:**


- Legible para humanos y máquinas.
- Compatible con muchos lenguajes (JavaScript, Python, etc.).
- Ideal para APIs RESTful (intercambio entre cliente y servidor).

- **Ejemplo:**

Cuando consumes una API de clima, puedes recibir una respuesta así:

```
{
  "ciudad": "Lima",
  "temperatura": 25,
  "clima": "Soleado"
}
```

6. SISTEMAS DE ALMACENAMIENTO EN LA NUBE: ALMACENAMIENTO EN BLOQUES, ARCHIVOS Y OBJETOS. SERVICIOS COMO AWS S3, GOOGLE CLOUD STORAGE, AZURE BLOB STORAGE.



[Servicios](#)

- **Almacenamiento por Bloques:**

- Similar a un disco duro.
- Se divide en bloques que pueden ser tratados por separado.
- Ejemplo: Amazon EBS (Elastic Block Store).
- Uso: Bases de datos, aplicaciones con alta E/S.
- Alta velocidad de acceso.
- Más técnico de administrar

- **Almacenamiento por Archivos:**

- Organizado en carpetas y rutas, como en tu computadora.
- Ejemplo: Amazon EFS, Azure Files.
- Uso: Compartir archivos entre servidores.
- Familiar y fácil de usar.
- Menos eficiente para Big Data.


- **Almacenamiento de Objetos:**

- Cada archivo se guarda como un objeto con metadatos.
- Ejemplo: Amazon S3, Google Cloud Storage, Azure Blob Storage.
- Uso: Big Data, backups, imágenes, videos, documentos.
- Escalable, económico, ideal para grandes volúmenes.
- No apto para modificar partes internas de un archivo.

TAREA N° 03

Conoce herramientas de procesamiento de datos para Big Data.

1. FRAMEWORKS DE PROCESAMIENTO DE DATOS: CONCEPTOS, ESTRUCTURA Y FUNCIONAMIENTO DE HADOOP, SPARK Y FLINK.



[HADOOP, SPARK Y FLINK](#)

- ¿Qué es un framework de procesamiento de datos?

Es una plataforma que permite manejar y analizar grandes volúmenes de datos de forma distribuida (varios servidores trabajando en conjunto).

- Hadoop

- **Concepto:** Ecosistema para el almacenamiento y procesamiento de datos masivos.
- **Estructura:** Usa HDFS (almacenamiento) + MapReduce (procesamiento por lotes).
- **Funcionamiento:** Divide tareas en bloques y los distribuye entre varios nodos.
- Escalable, tolerante a fallos.
- Lento para análisis en tiempo real.


- **Spark**

- **Concepto:** Motor de procesamiento rápido para Big Data.
- **Estructura:** Usa RDDs (Resilient Distributed Datasets) y permite procesamiento en memoria.
- **Funcionamiento:** Opera datos directamente en RAM, mucho más rápido que Hadoop.
- Súper rápido, permite tiempo real.
- Requiere más memoria.

- **Flink**

- **Concepto:** Framework especializado en procesamiento de flujos de datos en tiempo real.
- **Estructura:** Funciona como Spark pero con un enfoque en eventos continuos.
- **Funcionamiento:** Ideal para casos como monitoreo en vivo, análisis de logs o sensores.

2. MAPREDUCE: MODELO DE PROGRAMACIÓN DISTRIBUIDA BASADO EN FUNCIONES DE MAPEO Y REDUCCIÓN.



[MapReduce](#)

- **¿Qué es MapReduce?**

Es un modelo creado por Google que divide el procesamiento en dos funciones básicas:

- **Map (Mapeo):** Lee datos y los organiza en pares clave-valor.
- **Reduce (Reducción):** Agrupa y resume los datos con base en las claves.

- **Ejemplo práctico:**

Contar cuántas veces aparece cada palabra en un libro:

- **Map:** “gato”, “perro”, “gato” → {“gato”: 1}, {“perro”: 1}, {“gato”: 1}
- **Reduce:** {“gato”: 2}, {“perro”: 1}

- **Usado en:**

Hadoop MapReduce y como base conceptual para otros motores.

3. COMPARATIVA ENTRE SPARK Y HADOOP MAPREDUCE: VELOCIDAD DE PROCESAMIENTO EN MEMORIA, TOLERANCIA A FALLOS, Y FLEXIBILIDAD.

Característica	Hadoop MapReduce	Apache Spark
Velocidad	Lento (procesa desde disco)	Rápido (procesa en memoria RAM)
Procesamiento	Por lotes	Lotes y tiempo real
Tolerancia a fallos	Alta (replicación en HDFS)	Alta (uso de DAG y recomputación)
Facilidad de uso	Complejo (mucho código en Java)	Más simple (soporta Python, Scala)
Flexibilidad	Limitado a MapReduce	Amplio: MLlib, GraphX, Spark SQL

[Comparativa \[Elaboración propia\]](#)

- **Ejemplo:**

- Hadoop MapReduce sería como un repartidor que entrega un paquete y vuelve por otro (lento).
- Spark sería como un repartidor con una camioneta llena de paquetes listos para entregar (rápido).

4. COMPONENTES DE PROCESAMIENTO DISTRIBUIDO: NODOS MAESTROS Y TRABAJADORES, CLÚSTER MANAGERS, DRIVERS, EJECUTORES.

En un sistema Big Data distribuido, varias máquinas trabajan en conjunto. Estos son sus principales componentes:

- **Nodos Maestros (Master Nodes):**

- Coordinan y gestionan todo el clúster.
- Toman decisiones sobre qué nodo hace qué tarea.
- Ejemplo en Spark: Driver.

- **Nodos Trabajadores (Worker Nodes):**

- Ejecutan las tareas asignadas.
- Hacen el trabajo pesado: almacenamiento, procesamiento, lectura/escritura.
- **Ejemplo:** Ejecutores en Spark, DataNodes en Hadoop.

- **Cluster Manager:**

- Administra los recursos de todo el clúster (CPU, RAM, nodos).
- Asigna recursos a las aplicaciones.
- Ejemplos: YARN (Hadoop), Kubernetes, Mesos, Spark Standalone.

- **Driver:**

- Programa principal que inicia y coordina una aplicación Spark.
- Planifica tareas, se comunica con el Cluster Manager y recopila resultados.


- **Ejecutores (Executors):**

- Procesos que corren en los nodos trabajadores.
- Ejecutan las tareas y devuelven los resultados al Driver.

- **Analogía didáctica:**

- El Driver es el jefe de proyecto.
- Los Ejecutores son los programadores.
- El Cluster Manager es el gerente de recursos (organiza escritorios, sillas, tiempo).
- Los Workers son las computadoras donde ocurre todo.

5. CONTENEDORES Y VIRTUALIZACIÓN LIGERA: USO DE DOCKER PARA IMPLEMENTAR ENTORNOS BIG DATA MODULARES.



[Docker](https://www.docker.com/)

- **¿Qué es Docker?**

Es una plataforma que permite empaquetar aplicaciones con todas sus dependencias para que puedan ejecutarse en cualquier entorno de forma rápida y consistente.

- **Ventajas para Big Data:**

- **Entornos modulares:** puedes separar por capas (ingesta, procesamiento, visualización).
- **Portabilidad:** se ejecuta igual en una laptop, servidor o nube.

- **Aislamiento:** sin conflictos entre servicios o versiones.

- **Ejemplo real:**


Un entorno Big Data puede tener:

- **Contenedor 1:** Kafka (ingesta)
- **Contenedor 2:** Spark (procesamiento)
- **Contenedor 3:** MongoDB (almacenamiento)
- **Contenedor 4:** Superset (visualización)

Y todo se levanta en segundos con un archivo docker-compose.yml.

6. PIPELINE DE PROCESAMIENTO DE DATOS: ETAPAS DESDE LA INGESTA HASTA LA AGREGACIÓN DE RESULTADOS.

Es un conjunto de etapas que sigue la información desde que se genera hasta que se convierte en conocimiento útil.



[Pipeline](#)

- **Etapas típicas de un pipeline Big Data:**

- **Ingesta:**
 - Captura de datos desde sensores, APIs, logs, etc.
 - Herramientas: Kafka, Flume, NiFi.
- **Almacenamiento:**
 - Guarda los datos en crudo (raw) o preprocesados.

- Sistemas: HDFS, S3, bases NoSQL.
- **Procesamiento:**
 - Transforma, filtra, limpia y analiza los datos.
 - Frameworks: Spark, Flink.
- **Agregación:**
 - Resume los datos (suma, promedio, conteo).
 - Se preparan para visualización o decisiones.
- **Visualización y Reporting:**
 - Resultados mostrados en dashboards o reportes.
 - Herramientas: Power BI, Tableau, Grafana.

TAREA N° 04

Revisa y conoce las aplicaciones en el mercado del Big Data.

1. PANORAMA ACTUAL DEL BIG DATA: TENDENCIAS EN TIEMPO REAL, ANALÍTICA PREDICTIVA, ANALÍTICA PRESCRIPTIVA Y VISUALIZACIÓN AVANZADA.

- **Panorama actual**

Big Data evoluciona hacia soluciones más inteligentes, automatizadas y en tiempo real. Estas son las principales tendencias:

- **Tendencias en Tiempo Real**

- Análisis de datos al instante para tomar decisiones inmediatas.
- **Ejemplo:** Detección de fraudes en tarjetas de crédito en segundos.

- **Analítica Predictiva**

- Usa modelos estadísticos o de machine learning para predecir futuros escenarios.
- **Ejemplo:** Predicción de demanda de productos en supermercados o fallas en maquinaria.

- **Analítica Prescriptiva**

- No solo predice, sino recomienda acciones a tomar.
- **Ejemplo:** Un sistema que sugiere reabastecer inventario según ventas previstas.

- **Visualización Avanzada**

- Presenta resultados complejos de manera intuitiva y visual.
- **Herramientas:** Tableau, Power BI, Looker.
- **Ejemplo:** Mapas de calor interactivos con zonas de alto consumo energético.

- **Ventajas:** Alta escalabilidad, integración con IA/ML, gran comunidad.
- **Google Cloud Platform (GCP)**
 - **Herramientas clave:** BigQuery (SQL sobre Big Data), Cloud Storage, Dataflow (procesamiento en streaming).
 - **Ventajas:** Potente para analítica en tiempo real y aprendizaje automático.
- **Microsoft Azure**
 - **Herramientas clave:** Azure Synapse Analytics, Data Lake, HDInsight (Spark/Hadoop), Azure Machine Learning.
 - **Ventajas:** Integración con Excel, Power BI y otras herramientas empresariales.



[Servicios de nube](#)

4. CLASIFICACIÓN DE DATOS SEGÚN SENSIBILIDAD: DATOS PERSONALES, CONFIDENCIALES, SENSIBLES Y PÚBLICOS.

- **Datos Públicos**
 - Accesibles sin restricciones legales.
 - **Ejemplo:** Horarios de transporte público, estadísticas de población.
- **Datos Personales**
 - Identifican directa o indirectamente a una persona.

- **Ejemplo:** Nombre, DNI, correo electrónico, número de teléfono.

- **Datos Confidenciales**

- Información privada de una organización o individuo que no debe compartirse sin autorización.
- **Ejemplo:** Contraseñas, estrategias empresariales, historial académico.

- **Datos Sensibles**

- Datos personales que, si se exponen, pueden afectar la privacidad o seguridad del individuo.
- **Ejemplo:** Orientación sexual, afiliación política, estado de salud, antecedentes penales.

5. CONCEPTOS LEGALES APLICADOS A BIG DATA: INTRODUCCIÓN A GDPR, LEY DE PROTECCIÓN DE DATOS PERSONALES, Y PRINCIPIOS DE PRIVACIDAD POR DISEÑO.

El manejo de datos masivos debe cumplir leyes y principios éticos. Estos son los más importantes:

- **GDPR (General Data Protection Regulation) - Unión Europea**



[GDPR](#)

- Regula cómo se recolectan, almacenan y procesan los datos personales.
- **Principios clave:**
 - Consentimiento informado.

- Derecho al olvido.
- Portabilidad de datos.
- Minimización (solo lo necesario).
- Aplicación real: Si una app europea recolecta tus datos, debe pedir tu consentimiento claro y permitir que los borres si lo solicitas.
- **PE Ley de Protección de Datos Personales – Perú (Ley N.º 29733)**



[Protección de datos](#)

- Similar al GDPR, regula el tratamiento de datos personales.
- **Requiere:**
 - Consentimiento del titular.
 - Registro de bancos de datos en la Autoridad Nacional.
 - Implementación de medidas de seguridad.
- **Ejemplo:** Una universidad debe proteger los datos de sus estudiantes y no puede venderlos sin autorización.
- **Privacidad por diseño (Privacy by Design)**
 - **Principio de seguridad proactiva:** la protección de datos debe estar incorporada desde la fase de diseño de un sistema.
 - **Ejemplo:** Una app que desde el inicio incluye encriptación, opciones para anonimizar y botones de eliminación de cuenta.

REFERENCIAS

- Gandomi, A., & Haider, M. (2015). Beyond the hype: Big data concepts, methods, and analytics. *International Journal of Information Management*, 35(2), 137–144. <https://doi.org/10.1016/j.ijinfomgt.2014.10.007>
- European Union. (2016). Regulation (EU) 2016/679 of the European Parliament and of the Council (General Data Protection Regulation – GDPR). <https://eur-lex.europa.eu/legal-content/EN/TXT/?uri=CELEX%3A32016R0679>
- Congreso de la República del Perú. (2011). Ley N.º 29733 - Ley de Protección de Datos Personales. <https://www.minjus.gob.pe/proteccion-de-datos-personales/>
- Apache Software Foundation. (n.d.). Apache Hadoop. <https://hadoop.apache.org/>
- Apache Software Foundation. (n.d.). Apache Spark. <https://spark.apache.org/>
- Docker Inc. (n.d.). What is Docker?. <https://www.docker.com/resources/what-container/>
- Amazon Web Services (AWS). (n.d.). Big Data on AWS. <https://aws.amazon.com/big-data/>
- Google Cloud. (n.d.). Big Data & Machine Learning Products. <https://cloud.google.com/products/data-analytics>
- Microsoft Azure. (n.d.). Azure Big Data and Analytics Solutions. <https://azure.microsoft.com/en-us/solutions/big-data/>
- Neo4j. (n.d.). Graph Database Platform. <https://neo4j.com/>
- MongoDB Inc. (n.d.). MongoDB Documentation. <https://www.mongodb.com/docs/>
- The Apache Software Foundation. (n.d.). Apache Flink. <https://flink.apache.org/>

